


Nabila Karin | 71478

Consumer Sentiment Analysis on **Redmi Products**

using **NLP** and **Machine learning**



Daftar Isi

1

Data

2

Tujuan Analisis

3

Preprocessing Data

4

Struktur Pelabelan + Machine Learning

5

Metode Labeling **NLTK**

6

Metode Labeling **TextBlob**

7

Metode Labeling **BERT**

8

Perbandingan Model

9


Analisis Tambahan

10

Kesimpulan

11

Saran Bisnis



About Data

Customer Feedback Dataset merupakan dataset ulasan produk elektronik/smartphone Redmi 6, lengkap dengan review dan rating yang diambil dari Amazon.com.



278 Row Data

Review Title	Judul singkat dari ulasan pengguna	Category	Kategori dari produk, misalnya "Battery", "Display", dll
Customer Name	Nama customer	Comments	Ulasan pengguna terhadap suatu produk
Rating	Penilaian pengguna dalam bentuk bintang (1 s.d 5)	Useful	Berapa banyak pengguna lain menganggap ulasan tersebut bermanfaat
Date	Tanggal review diposting		



Tujuan Analisis




Melakukan Perbandingan Metode Pelabelan Sentimen



Mengidentifikasi Metode Pelabelan Sentimen yang Paling Akurat




Melakukan Analisis Lanjutan dari Model Terbaik



Preprocessing Data

Sebelum melakukan analisis, dilakukan *take out* (menghapus atau memilih kolom) yang tidak akan digunakan dalam analisis.



- **Customer Name**

Tidak dilakukan analisis pada kolom tersebut


- **Rating**

Mengubah tipe data string menjadi float

- **Date**

Mengkonversi tipe data string ke format datetime.

Terdapat enam kolom yang akan digunakan untuk **analisis pelabelan**.



Struktur Pelabelan + Machine Learning

1

Preprocessing
Data

2

Pelabelan
Data

3

Split
Data

4

Inisialisasi dan
latih model SVC

Metode Labeling NLTK



NLTK dengan VADER (Valence Aware Dictionary and sEntiment Reasoner) adalah metode analisis sentimen berbasis leksikon yang tersedia dalam library Python NLTK.

VADER dirancang khusus untuk menganalisis sentimen dalam teks pendek seperti komentar atau ulasan pengguna dengan memperhitungkan intensitas emosi dari kata-kata

Penilaian Utama NLTK

Setiap kata dalam kalimat diberi nilai (positif/negatif/netral).

Misalnya :


- “excellent” = +2.5
- “bad” = -2.5
- “not bad” → NLTK bisa mengenali sebagai positif karena mengenali negation.

```
# Fungsi untuk memberi label berdasarkan skor
def label_sentiment(score):
    ... if score <= -0.05:
    ...     return 0 # Negatif
    ... elif score >= 0.05:
    ...     return 2 # Positif
    ... else:
    ...     return 1 # Netral
```

Komentar diberi label Negatif jika skornya ≤ -0.05 , Positif jika $\geq +0.05$, dan Netral untuk yang berada di antaranya.


	Comments	# sentiment_score	# sentiment_label	sentiment_label_text
0	Another Midrange killer Smartphone	0.9981	2	Positif
1	All ok but vry small size mobile	0.1531	2	Positif
2	Quite good	0.4927	2	Positif
3	Redmi has always have been the the	0.961	2	Positif
4	worst product from MI. I am a hardc	-0.7677	0	Negatif
5	Over prised by at least around Rs.10	0.9456	2	Positif
6	Pros: notch display Dual camera Face	0.802	2	Positif
7	Front camera is poor rest things are	-0.0516	0	Negatif
8	Wooo	0.0	1	Netral
9	Realme is sub brand of oppo He give	0.897	2	Positif

```
✚ Jumlah Masing-Masing Label pada Model NLTK:
sentiment_label_text
Positif      214
Negatif       36
Netral        30
Name: count, dtype: int64
```



Hasil Labeling **NLTK** + **SVC**

Menggunakan model machine learning (Support Vector Classification) untuk mempelajari pola sentimen dari komentar pelanggan yang telah dilabeli otomatis oleh NLTK VADER, agar kita bisa mempercepat klasifikasi komentar baru secara akurat dan skalabel.



Classification Report:				
	precision	recall	f1-score	support
Negatif	0.00	0.00	0.00	4
Netral	1.00	0.20	0.33	5
Positif	0.85	1.00	0.92	47
accuracy			0.86	56
macro avg	0.62	0.40	0.42	56
weighted avg	0.81	0.86	0.80	56

Accuracy (86%)	Akurasi tidak menunjukkan performa yang seimbang antar kelas.
Precision	Precision untuk komentar negatif adalah 0.00, menunjukkan bahwa model tidak mampu mengidentifikasi komentar negatif dengan benar sama sekali
Recall	Performanya sangat rendah pada komentar netral (20%) dan gagal total pada komentar negatif (0%).
F1 Score	Sangat baik dalam mengenali komentar positif (0.92), namun gagal total dalam mendeteksi komentar negatif (0.00) dan masih lemah dalam mengenali komentar netral (0.33).

Metode Labeling TextBlob

TextBlob adalah library NLP sederhana berbasis Python yang menyediakan fungsi analisis sentimen menggunakan rule-based + probabilistic model (berbasis Naive Bayes classifier dan lexicon).

TextBlob menghitung polarity dan subjectivity.

Penilaian Utama TextBlob

Kombinasi kata dan struktur kalimat.
Fokus pada polaritas (positif/negatif) dan subjectivity (fakta atau opini).

Misalnya :

- "This phone is very good" → polaritas = +0.85
- "Not very helpful" → polaritas = -0.4

```
# Labeling berdasarkan skor polaritas
def label_sentiment(score):
    if score <= -0.2:
        return 0 # Negatif
    elif score >= 0.2:
        return 2 # Positif
    else:
        return 1 # Netral
```

Komentar diberi label Negatif jika skor polaritasnya ≤ -0.2 , Positif jika $\geq +0.2$, dan Netral jika berada di antara kedua nilai tersebut. Penetapan kategori sentimen berdasarkan kekuatan opini yang terkandung dalam teks komentar.


Comments	# sentiment_score	# sentiment_label	sentiment_label_text
0 Another Midrange killer Smartphone	0.23826059969442315	2	Positif
1 All ok but vry small size mobile	0.125	1	Netral
2 Quite good	0.7	2	Positif
3 Redmi has always have been the the	0.14348958333333334	1	Netral
4 worst product from MI. I am a hardc	-0.8	0	Negatif
5 Over prised by at least around Rs.10l	0.44117647058823534	2	Positif
6 Pros: notch display Dual camera Face	0.33749999999999997	2	Positif
7 Front camera is poor rest things are	0.14999999999999997	1	Netral
8 Wooo	0.0	1	Netral
9 Realme is sub brand of oppo He give	0.3	2	Positif

📌 Jumlah Masing-Masing Label pada Model TextBlob:

```
sentiment_label_text
Positif      187
Netral       73
Negatif      20
Name: count, dtype: int64
```

Hasil Labeling TextBlob + SVC

Menggunakan model machine learning (Support Vector Classification) untuk mempelajari pola sentimen dari komentar pelanggan yang telah dilabeli berdasarkan polaritas oleh TextBlob.



Classification Report:				
	precision	recall	f1-score	support
Negatif	1.00	0.25	0.40	4
Netral	0.69	0.60	0.64	15
Positif	0.86	0.97	0.91	37
accuracy			0.82	56
macro avg	0.85	0.61	0.65	56
weighted avg	0.82	0.82	0.80	56

Accuracy (82%)	Akurasi model cukup tinggi secara keseluruhan, tetapi belum merepresentasikan performa seimbang antar label.
Precision	Precision untuk komentar negatif sangat tinggi (1.00). Precision untuk netral 0.69 dan positif 0.86, menunjukkan model cukup andal dalam memprediksi komentar positif.
Recall	Model hanya berhasil menangkap 25% komentar negatif dan 60% komentar netral, tetapi sangat baik dalam mengenali komentar positif (97%).
F1 Score	F1-score tertinggi pada komentar positif (0.91), cukup baik pada netral (0.64), namun masih rendah pada komentar negatif (0.40).

Metode Labeling BERT

BERT (Bidirectional Encoder Representations from Transformers) adalah model transformer-based yang dilatih secara kontekstual dua arah, dan bisa digunakan untuk sentimen analysis.

BERT membaca kalimat dari dua arah (kiri dan kanan) dan mengerti sinonim, ironi, negasi, dan kalimat panjang/kompleks.

Penilaian Utama TextBlob

Input teks dikonversi menjadi token.

Dimasukkan ke model BERT → menghasilkan prediksi label sentimen yang diubah ke label.

Misalnya :

- “Camera is not as good as expected” → bisa dipahami sebagai keluhan, meski tidak eksplisit pakai kata “bad” atau kata buruk lainnya.

Comments	# label	sentiment_label_text
Another Midrange killer Smartphone	2	Positif
All ok but vry small size mobile	1	Netral
Quite good	2	Positif
Redmi has always have been the the	2	Positif
worst product from MI. I am a hardc	0	Negatif
Over prised by at least around Rs.10l	0	Negatif
Pros: notch display Dual camera Face	2	Positif
Front camera is poor rest things are	1	Netral
Wooo	1	Netral
Realme is sub brand of oppo He give	2	Positif

```
def label_sentiment(text):
    inputs = tokenizer(text, return_tensors='pt', truncation=True, padding='max_length', max_length=512)
    with torch.no_grad():
        outputs = classifier_model(**inputs)
    probs = torch.nn.functional.softmax(outputs.logits, dim=1)
    pred_class = torch.argmax(probs, dim=1).item() + 1
    if pred_class <= 2:
        return 0 # Negatif
    elif pred_class == 3:
        return 1 # Netral
    else:
        return 2 # Positif
df_bert_clean['label'] = df_bert_clean['Comments'].astype(str).apply(label_sentiment)
```


Komentar diberi label Negatif jika prediksi model BERT menunjukkan skor bintang 1 atau 2, Positif jika memperoleh skor bintang 4 atau 5, dan Netral jika berada pada skor bintang 3. Penetapan kategori sentimen dilakukan berdasarkan penilaian konteks dan makna keseluruhan dari teks komentar.

✦ Jumlah Masing-Masing Label pada Model BERT:

```
sentiment_label_text
Positif      181
Negatif       65
Netral        34
Name: count, dtype: int64
```


Hasil Labeling BERT + SVC

Menggunakan model machine learning (Support Vector Classification) untuk mempelajari pola sentimen dari keseluruhan komentar pelanggan yang diubah ke token dan dilabeli oleh BERT.




	precision	recall	f1-score	support
Negatif	0.56	0.91	0.69	11
Netral	0.75	0.30	0.43	10
Positif	0.94	0.91	0.93	35
accuracy			0.80	56
macro avg	0.75	0.71	0.68	56
weighted avg	0.83	0.80	0.79	56

Accuracy (80%)	Akurasi keseluruhan yang tinggi sebesar 80%, yang menjadi indikator bahwa model mampu mengklasifikasikan komentar dengan baik.
Precision	Precision tertinggi pada komentar positif (0.94), disusul netral (0.75) dan negatif (0.56), menjadikan BERT model paling akurat dan seimbang dalam mengenali sentimen.
Recall	Model BERT sangat kuat dalam menangkap komentar negatif dan positif (keduanya sebesar 91%), dan meskipun recall untuk komentar netral masih rendah (30%).
F1 Score	F1-score pada komentar positif mencapai 0.93, tertinggi di antara semua model. Komentar negatif juga memiliki F1-score yang baik (0.69), sementara netral (0.43) masih dapat ditingkatkan.

Perbandingan Model

	Model	Label	Precision	Recall	F1-Score	Support
0	NLTK	Negatif	0.00	0.00	0.00	4
1	NLTK	Netral	1.00	0.20	0.33	5
2	NLTK	Positif	0.85	1.00	0.92	47
3	TextBlob	Negatif	1.00	0.25	0.40	4
4	TextBlob	Netral	0.69	0.60	0.64	15
5	TextBlob	Positif	0.86	0.97	0.91	37
6	BERT	Negatif	0.56	0.91	0.69	11
7	BERT	Netral	0.75	0.30	0.43	10
8	BERT	Positif	0.94	0.91	0.93	35

- **NLTK** hanya sangat baik pada label Netral (precision = 1.00), namun gagal pada Negatif (0.00) dan kurang seimbang pada Positif meskipun F1-score-nya cukup tinggi (0.92).
- **TextBlob** memiliki keseimbangan yang lebih baik dengan precision tinggi di semua label (Negatif: 1.00, Netral: 0.69, Positif: 0.86), namun masih rendah dari sisi recall untuk Negatif (0.25) dan Netral (0.60).
- **BERT** menunjukkan performa paling konsisten dan unggul di seluruh label, dengan F1-score tertinggi untuk Positif (0.93), cukup baik untuk Negatif (0.69), dan Netral (0.43) walaupun masih dapat ditingkatkan.



Model BERT unggul secara keseluruhan, terutama dalam mengenali komentar Negatif dan Positif yang menjadi fokus utama dalam analisis kepuasan pelanggan.




Akan dilakukan analisis lanjutan menggunakan hasil Labeling dari Model BERT.



Distribusi Sentimen Konsumen Berdasarkan Kategori Produk


Menampilkan jumlah komentar konsumen berdasarkan kategori produk dan label sentimen (Negatif, Netral, Positif).




Insight Bisnis

- **Camera** menimbulkan cukup banyak komentar negatif. Ini bisa menjadi sinyal bahwa fitur kamera perlu dievaluasi ulang atau ditingkatkan.
- Kategori **Others** perlu ditelusuri lebih lanjut isinya, karena meskipun dominan positif, komentar negatif dan netral juga signifikan.
- **Battery** dan **Display** memiliki tingkat sentimen positif yang tinggi dengan sedikit keluhan, sehingga dapat dijadikan unggulan dalam promosi produk.

Misalnya, promosi: "Daya tahan baterai yang tahan lama & tampilan layar yang tajam!"








Insight Bisnis


1. **Perlu evaluasi pada kamera & kualitas ponsel** : Kamera dan performa menjadi titik keluhan tertinggi. **Tim produk sebaiknya meninjau ulang spesifikasi teknis dan kualitas material.**
2. **Tingkatkan QC dan dukungan teknis** : Keluhan terkait “working”, “issue”, dan “bad” menunjukkan **potensi kegagalan fungsi yang bisa diperbaiki melalui quality control (QC) yang lebih ketat.**
3. **Brand trust perlu dijaga** : Munculnya kata “mi”, “redmi”, dan “amazon” di komentar negatif mengindikasikan adanya ketidakpuasan yang melekat pada brand dan saluran distribusi. **Perlu komunikasi brand yang lebih kuat dan perbaikan layanan pelanggan.**





Perkembangan Sentimen Pelanggan dari Hari ke Hari

Menunjukkan bagaimana persepsi pelanggan berubah seiring waktu terhadap produk Redmi. Grafik menampilkan jumlah komentar berdasarkan label sentimen (Negatif, Netral, Positif) yang dipetakan terhadap tanggal.



- Sentimen positif mendominasi setiap hari, terlihat dari garis hijau yang konsisten berada di atas.
- Ada beberapa lonjakan tajam pada komentar positif, misalnya pada 18–21 September dan 25 September—mungkin menandakan adanya kampanye, promosi, atau peluncuran produk yang berhasil.
- Komentar negatif dan netral relatif stabil dan lebih rendah jumlahnya, namun tetap muncul setiap hari.
- Terlihat bahwa komentar netral cenderung flat, menunjukkan beberapa pelanggan bersikap biasa saja terhadap produk

Insight Bisnis

1. Kampanye pemasaran pada pertengahan September kemungkinan besar berhasil, ditunjukkan oleh puncak sentimen positif yang signifikan.
2. Konsistensi komentar positif menunjukkan kepuasan pelanggan yang tinggi, yang bisa dimanfaatkan untuk promosi testimoni.
3. Komentar negatif masih muncul setiap hari, yang berarti perusahaan tetap perlu meningkatkan kualitas layanan atau fitur produk tertentu.



Dengan memantau sentimen pelanggan harian, kita bisa mendeteksi potensi masalah lebih cepat dan mengoptimalkan waktu terbaik untuk merilis kampanye atau produk.

Kesimpulan



Dari hasil perbandingan pemodelan, Model BERT memberikan hasil paling akurat dan konsisten, terutama dalam mendeteksi komentar positif dan negatif, menjadikannya pilihan terbaik untuk pelabelan otomatis.




Dari Keyword Analysis, Keyword seperti “bad”, “issue”, dan “redmi” muncul di komentar negatif, menandakan perlunya peningkatan kualitas produk, pelayanan, dan penguatan brand trust.



Fitur kamera paling sering dikeluhkan, diikuti isu kualitas dan performa menunjukkan perlunya evaluasi dan peningkatan pada aspek teknis produk.



Komentar positif mendominasi secara konsisten setiap hari, terutama saat kampanye tertentu—menandakan keberhasilan promosi dan tingginya kepuasan pelanggan.





Saran Bisnis

1

Gunakan model BERT untuk pelabelan sentimen otomatis ke depannya karena paling stabil dan akurat.

2

Lakukan perbaikan pada fitur kamera dan kualitas perangkat yang paling banyak dikritik.

3



Tingkatkan brand communication untuk menumbuhkan kembali kepercayaan terhadap Redmi, khususnya di kanal distribusi seperti marketplace.

4

Jadikan Battery & Display sebagai fitur unggulan promosi, berdasarkan data kepuasan konsumen.

5

Lakukan monitoring harian sentimen agar perusahaan lebih cepat merespons perubahan persepsi pasar dan meningkatkan loyalitas pelanggan.



Terima Kasih

Nabila Karin | 71478

